인간 단백질의 아미노산 서열 길이와 Gene Ontology 기능 주석 개수의 관계에 관한 탐색적 분석

An Exploratory Analysis of Protein Sequence Length
and Gene Ontology Annotation Counts
in Human Reviewed Proteins

2026년 11월 2일

목차

국문 초록 ii

Abstract iii

1. 서론 (Introduction) 1

2. 연구 방법 (Methods) 3

3. 연구 결과 (Results) 5

표 1. 주요 변수의 기술통계 5

그림 1. 인간 Reviewed 단백질의 아미노산 서열 길이 분포 5

그림 2. 인간 Reviewed 단백질의 전체 고유 GO 주석 개수 분포 6

그림 3. 아미노산 서열 길이와 전체 고유 GO 주석 개수의 관계 7

표 2. 서열 길이와 GO 주석 개수의 Spearman 상관분석 7

그림 4. GO 범주별 Spearman 상관계수 및 95% 신뢰구간 8

표 3. 분석 대상 선정 기준에 따른 민감도 분석 8

4. 논의 (Discussion) 9

5. 결론 (Conclusion) 11

참고문헌 12

국문 초록

연구 목적: 단백질의 아미노산 서열 길이는 단백질의 구조 및 기능과 관련된 기본적인 특성이다. 그러나 서열 길이와 데이터베이스에 기록된 기능 주석의 양 사이의 관계는 주석의 불완전성과 편향을 고려하여 해석할 필요가 있다. 본 연구에서는 인간 단백질의 아미노산 서열 길이와 Gene Ontology(GO) 주석 개수 사이의 연관성을 탐색적으로 분석하였다.

연구 방법: UniProtKB Release 2026_03에서 인간 Reviewed 단백질 20,431개를 수집하였다. 각 단백질의 아미노산 서열 길이와 고유 GO ID 개수를 산출하고, Spearman 순위상관분석을 통해 두 변수 사이의 단조 연관성을 평가하였다. 또한 Biological Process(BP), Molecular Function(MF), Cellular Component(CC) 범주별 분석과 두 가지 민감도 분석을 수행하였다. 상관계수의 95% 신뢰구간은 2,000회 paired bootstrap으로 산출하였다.

연구 결과: 아미노산 서열 길이와 전체 GO 주석 개수 사이에는 약한 양의 상관관계가 관찰되었다 (Spearman $\rho = 0.2705$, 95% CI [0.2570, 0.2840], $p < 0.001$). BP($\rho = 0.2280$), MF($\rho = 0.2592$), CC($\rho = 0.2464$)에서도 양의 연관성이 관찰되었다. GO 주석이 없는 단백질을 제외한 분석에서는 $\rho = 0.2331$, 단일 Gene ID 기준으로 분석 대상을 제한한 경우에는 $\rho = 0.2013$으로 감소하였으나, 양의 연관성은 유지되었다.

결론: 인간 Reviewed 단백질에서 아미노산 서열 길이와 고유 GO 주석 개수 사이에 약한 양의 연관성이 관찰되었다. 그러나 연관성의 크기는 분석 대상 선정 기준에 따라 달라졌으며, GO 주석 개수는 실제 생물학적 기능의 수를 직접 나타내지 않는다. 따라서 본 연구 결과는 데이터베이스에 기록된 기능 주석량에 관한 탐색적 연관성으로 해석해야 한다.

주요어: 단백질 서열 길이, Gene Ontology, UniProtKB, 기능 주석, Spearman 상관분석, 생물정보학

Abstract

Background: Protein sequence length is a fundamental characteristic associated with protein structure and function. However, the relationship between sequence length and the number of functional annotations recorded in biological databases requires careful interpretation because of annotation incompleteness and potential biases. This study investigated the association between amino acid sequence length and Gene Ontology (GO) annotation counts in human proteins.

Methods: A total of 20,431 human reviewed protein entries were retrieved from UniProtKB release 2026_03. Amino acid sequence length and the number of unique GO identifiers were determined for each protein. Spearman's rank correlation was used to assess their monotonic association. Additional analyses were performed for Biological Process (BP), Molecular Function (MF), and Cellular Component (CC) annotations. Two sensitivity analyses evaluated the effects of excluding proteins without GO annotations and restricting the dataset to one accession per uniquely mapped gene. Ninety-five percent confidence intervals were estimated using 2,000 paired bootstrap resamples.

Results: A weak positive association was observed between sequence length and total GO annotation count (Spearman's $\rho = 0.2705$, 95% CI [0.2570, 0.2840], $p < 0.001$). Positive associations were also observed for BP ($\rho = 0.2280$), MF ($\rho = 0.2592$), and CC ($\rho = 0.2464$). The correlation decreased after excluding proteins without GO annotations ($\rho = 0.2331$) and after restricting the dataset to one accession per uniquely mapped gene ($\rho = 0.2013$), while remaining positive in both analyses.

Conclusions: Amino acid sequence length was weakly positively associated with the number of unique GO annotations in human reviewed proteins. The magnitude of the association varied across dataset selection criteria. Because GO annotation counts reflect recorded database information rather than the actual number of biological functions, these findings should not be interpreted as evidence of a causal relationship between protein length and functional diversity.

Keywords: Protein sequence length; Gene Ontology; UniProtKB; Functional annotation; Spearman correlation; Bioinformatics

1. 서론 (Introduction)

1.1 연구 배경

단백질은 생명체 내에서 효소 반응, 물질 운반, 세포 신호 전달, 구조 유지 등 다양한 생물학적 과정에 관여하는 주요 생체분자이다. 단백질의 기능은 아미노산 서열, 구조적 특성, 상호작용 및 세포 내 환경 등 여러 요인과 관련되어 있다. 아미노산 서열 길이는 단백질의 기본적인 특성 중 하나이며, 단백질의 구조와 기능을 분석할 때 활용할 수 있는 정량적 변수이다. 그러나 단백질의 서열 길이만으로 해당 단백질이 수행하는 기능의 종류나 수를 직접 판단하기는 어렵다.

최근 생물정보학 분야에서는 대규모 단백질 데이터베이스를 활용하여 단백질의 서열과 기능 정보를 분석하는 연구가 활발하게 수행되고 있다. UniProtKB는 단백질 서열과 기능 관련 정보를 제공하는 대표적인 생물정보학 데이터베이스로, 전문가가 검토한 Reviewed 항목과 자동 주석 중심의 Unreviewed 항목을 제공한다 [1]. UniProtKB에 등록된 단백질 정보에는 아미노산 서열, 유전자 정보, 기능 설명 및 다양한 외부 데이터베이스의 주석 정보가 포함된다. 이러한 정보는 단백질의 생물학적 특성을 정량적으로 비교하는 연구의 기초 자료로 활용될 수 있다.

1.2 Gene Ontology와 기능 주석

Gene Ontology(GO)는 유전자 및 유전자 산물의 기능적 특성을 일관된 용어로 표현하기 위한 체계이다 [2]. GO는 다음 세 가지 범주로 구성된다.

- **Biological Process(BP):** 유전자 산물이 관여하는 생물학적 과정
- **Molecular Function(MF):** 유전자 산물이 수행하는 분자 수준의 활동
- **Cellular Component(CC):** 유전자 산물이 위치하거나 작용하는 세포 내 구성 요소

각 GO 용어는 고유한 GO ID로 식별되며, 단백질은 여러 GO 용어와 연결될 수 있다. 따라서 단백질에 연결된 고유 GO ID 개수를 계산하면 해당 단백질에 대해 데이터베이스에 기록된 기능 관련 정보의 양을 정량적으로 나타낼 수 있다. 그러나 GO 주석 개수가 많다는 사실이 해당 단백질의 실제 생물학적 기능 수가 많다는 의미는 아니다. GO 주석은 실험적 연구, 계산적 예측, 기존 지식의 전파 및 데이터베이스 큐레이션 등 다양한 과정을 통해 축적되기 때문이다.

1.3 선행연구 및 연구 필요성

GO 주석은 생물학적 기능 분석에 널리 활용되지만, 주석의 불완전성과 편향은 결과 해석에 영향을 미칠 수 있다. Gillis와 Pavlidis [3]는 GO 주석의 중복성, 시간에 따른 변화 및 편향을 분석하여 유전자별 주석 정보가 균등하게 분포하지 않는다는 점을 제시하였다. Gaudet과 Dessimoz [4]는 GO 기반 분석에서 주석의 불완전성, 근거 정보 및 계층 구조와 관련된 문제를 고려해야 한다고 설명하였다.

또한 Phan 등 [5]은 인간 단백질체의 기능 주석 정보를 종단적으로 분석하여 주석의 불균등성이 지속되고 있음을 보고하였다. 이러한 선행연구는 GO 주석 개수를 단백질의 실제 기능적 다양성과 동일하게 해석하는 데 주의가 필요함을 보여준다. 한편 단백질의 아미노산 서열 길이와 GO 주석 개수 사이의 관계를 정량적으로 분석하면, 단백질의 기본적인 서열 특성과 데이터베이스에 축적된 기능 정보 사이의 연관성을 탐색할 수 있다.

본 연구에서는 이 관계를 인과적으로 설명하기보다, 대규모 인간 Reviewed 단백질 데이터에서 관찰되는 통계적 연관성을 확인하고자 한다.

1.4 연구 목적 및 가설

본 연구의 목적은 인간 Reviewed 단백질의 아미노산 서열 길이와 고유 GO 주석 개수 사이의 관계를 탐색적으로 분석하는 것이다. 주요 연구 질문은 다음과 같다. **인간 Reviewed 단백질에서 아미노산 서열 길이가 길수록 고유 GO 주석 개수가 증가하는 경향이 존재하는가?** 이를 검토하기 위해 다음 가설을 설정하였다.

- **연구가설(H1):** 두 변수 사이의 Spearman 상관계수는 0이 아니다. 예상되는 연관성의 방향은 양(+)이다.
- **귀무가설(H0):** 두 변수 사이의 Spearman 상관계수는 0이다.

주요 분석에서는 전체 고유 GO 주석 개수를 사용하고, 보조 분석에서는 BP, MF, CC 범주별 주석 개수를 구분하여 분석하였다. 또한 GO 주석이 없는 단백질의 포함 여부와 Gene ID 기반 데이터 선정 기준에 따른 결과 변화를 확인하기 위해 민감도 분석을 수행하였다.

2. 연구 방법 (Methods)

2.1 연구 설계

본 연구는 인간 단백질의 아미노산 서열 길이와 GO 주석 개수 사이의 관계를 조사하기 위한 탐색적 횡단면 분석이다. 분석 단위는 UniProtKB의 primary accession으로 정의하였으며, 하나의 accession을 하나의 관측치로 사용하였다. 주요 독립변수는 단백질의 아미노산 서열 길이이고, 종속변수는 해당 단백질에 직접 연결된 고유 GO ID 개수이다.

2.2 데이터 출처 및 수집

데이터는 UniProtKB REST API를 통해 수집하였다 [1, 6]. 분석 대상은 분류학적 식별번호가 9606인 인간(Homo sapiens) 단백질 중 Reviewed로 분류된 항목으로 제한하였다. 검색 조건은 다음과 같다.

```
organism_id:9606 AND reviewed:true
```

2026년 10월 30일에 UniProtKB Release 2026_03(릴리스 날짜: 2026년 9월 2일)을 대상으로 전체 조건 일치 항목 20,431개를 수집하였다. REST API의 페이지네이션을 통해 JSON과 TSV 형식의 응답을 각각 41페이지에 걸쳐 수집하였다. 수집 과정에서는 전체 결과 건수, 릴리스 정보, 요청 메타데이터 및 파일 체크섬을 기록하였다. 수집된 JSON과 TSV의 accession 집합과 주요 필드를 비교하여 일관성을 확인하였으며, 전체 결과 건수와 최종 수집 항목 수가 일치하는지 검증하였다.

2.3 변수 정의

아미노산 서열 길이는 UniProtKB에서 제공하는 Length 필드를 이용하여 아미노산 잔기 수(aa)로 측정하였다. GO 주석 개수는 각 단백질에 연결된 GO ID를 추출하고 중복을 제거하여 계산하였다. 동일 단백질에 같은 GO ID가 여러 번 등장하더라도 한 번만 집계하였다. GO 주석은 Biological Process(BP), Molecular Function(MF), Cellular Component(CC)의 세 범주로 구분하였다 [2].

전체 GO 주석 개수와 세 범주별 고유 GO 주석 개수를 각각 산출하였다. GO 계층 구조의 상위 용어를 추가하는 조상 용어 전파는 수행하지 않았다. GO 주석이 등록되지 않은 단백질의 주석 개수는 0으로 기록하고 기본 분석에서 제외하지 않았다. 또한 GO 주석의 근거 코드에 따른 구분 없이 모든 고유 GO ID를 주요 분석에 포함하였다.

2.4 데이터 전처리 및 품질 검증

수집한 JSON 원본을 기준으로 분석용 CSV를 생성하였으며, TSV 응답은 주요 필드의 교차 검증에 사용하였다. 분석용 데이터셋은 다음 9개 컬럼으로 구성하였다.

```
accession, protein_name, gene_name, gene_id, sequence_length, go_total_count, go_bp_count, go_mf_count, go_cc_count
```

전처리 과정에서는 accession 중복, 서열 길이의 비정상 값, GO ID 형식 오류, GO 범주 분류 오류 및 JSON·TSV 간 주요 필드 불일치 여부를 검사하였다. 최종 분석용 데이터셋은 20,431행으로 구성되었으며, 주요 분석에 필요한 수치형 변수에서 결측값이나 형식 오류로 제외된 항목은 없었다. GO 주석이 없는 항목은 1,056개였으며, Gene ID가 없는 항목 1,277개와 복수 Gene ID에 매핑된 항목 99개도 기본 분석에 유지하였다.

2.5 기술통계 및 상관분석

서열 길이와 GO 주석 개수의 분포를 확인하기 위해 평균, 표준편차, 중앙값, 사분위수, 최솟값, 최댓값 및 왜도를 산출하였다. 주요 분석에서는 아미노산 서열 길이와 전체 고유 GO 주석 개수 사이의 Spearman 순위상관계수(ρ)를 계산하였다. Spearman 상관분석은 두 변수 사이의 단조 연관성을 평가하기 위한 방법으로, 본 연구에서 관찰된 비대칭 분포와 동률 순위를 고려하여 적용하였다.

상관계수의 통계적 유의성은 양측 검정으로 평가하였으며, 유의수준은 0.05로 설정하였다. p-value는 SciPy의 Spearman 상관분석에 사용되는 큰 표본 t 근사(df = n − 2)에 기반하여 계산하였다. 주요 분석에서는 float64 p값이 언더플로로 0을 반환하므로 동일한 t 분포 꼬리를 스케일 조정 적분하여 로그 p값과 과학적 표기값을 보존하였다. 이는 실제 p값이 0이라는 뜻이 아니다.

95% 신뢰구간은 관측치의 쌍을 함께 재표본추출하는 paired bootstrap 방법으로 산출하였다. 부트스트랩 반복 횟수는 2,000회였으며, 각 반복에서 Spearman 상관계수를 다시 계산하였다. 신뢰구간은 부트스트랩 분포의 2.5번째 및 97.5번째 백분위수를 이용하였다. 재현 가능한 분석을 위해 난수 시드는 20261030으로 고정하였다. 보조 분석에서는 BP, MF, CC별 GO 주석 개수와 서열 길이의 Spearman 상관계수를 각각 산출하였다.

세 보조 검정의 p-value에는 Holm 방법을 적용하여 다중검정을 보정하였다.

2.6 민감도 분석

주요 결과가 분석 대상 선정 방식에 따라 달라지는지 확인하기 위해 두 가지 민감도 분석을 수행하였다. 첫 번째 분석에서는 전체 GO 주석 개수가 0개인 단백질을 제외하고 상관계수를 다시 계산하였다. 두 번째 분석에서는 단일 Gene ID가 확인된 단백질만을 대상으로 유전자당 하나의 accession을 유지하였다. Gene ID가 누락되거나 복수 Gene ID에 매핑된 항목은 해당 민감도 분석에서 제외하였다.

동일 Gene ID에 여러 accession이 연결된 경우에는 accession을 오름차순으로 정렬하여 첫 번째 항목을 선택하였다. 이 규칙은 재현 가능한 중복 축소를 위한 것이며, 생물학적으로 대표적인 단백질을 선정하는 기준은 아니다. 두 민감도 분석에서도 주요 분석과 동일하게 Spearman 상관계수, 양측 p-value 및 95% 부트스트랩 신뢰구간을 계산하였다.

2.7 재현성 및 데이터 관리

전체 수집 및 전처리 과정은 Python 스크립트로 구현하였다. 원본 JSON·TSV 응답과 분석용 CSV는 별도로 보존하였다. 데이터 수집 조건, UniProtKB 릴리스, 수집 시각, 파일 체크섬, 데이터 검증 결과 및 분석 환경을 메타데이터에 기록하였다. 동일한 원본 데이터로 전처리를 반복했을 때 결과 파일의 체크섬이 일치하는지 확인하였으며, 통계 분석에서도 고정된 난수 시드를 사용하여 결과의 재현성을 확보하도록 하였다.

3. 연구 결과 (Results)

3.1 분석 대상 및 기술통계

본 연구에서는 UniProtKB Reviewed에 등록된 인간 단백질 20,431개를 분석하였다. 분석 과정에서 결측값이나 데이터 형식 오류로 제외된 항목은 없었으며, 모든 단백질을 주요 분석에 포함하였다. 아미노산 서열 길이의 평균은 558.87 aa(표준편차 608.44), 중앙값은 415 aa였으며, 최솟값은 2 aa, 최댓값은 34,350 aa였다. 전체 고유 GO 주석 개수의 평균은 12.12개(표준편차 12.79), 중앙값은 9개였으며, 최솟값은 0개, 최댓값은 163개였다(표 1).

표 1. 주요 변수의 기술통계

변수	평균	표준편차	중앙값	Q1-Q3	최솟값	최댓값
서열 길이(aa)	558.87	608.44	415	249-670	2	34,350
전체 GO	12.12	12.79	9	4-15	0	163
BP	5.36	8.11	3	1-6	0	148
MF	2.70	2.98	2	1-4	0	40
CC	4.05	3.82	3	1-5	0	46

주: 모든 변수의 n = 20,431. 표준편차는 표본 표준편차(ddof = 1)이며, Q1과 Q3는 선형 보간으로 계산한 25% 및 75% 분위수이다. GO 값의 단위는 고유 GO ID 개수이다. BP = Biological Process; MF = Molecular Function; CC = Cellular Component.

모든 변수에서 평균이 중앙값보다 크고 양의 왜도가 관찰되어 오른쪽으로 긴 꼬리를 갖는 비대칭 분포를 나타냈다(그림 1, 2). 전체 단백질 중 1,056개(5.17%)는 GO 주석이 등록되어 있지 않았으며, 해당 항목도 주요 분석에 포함하였다.

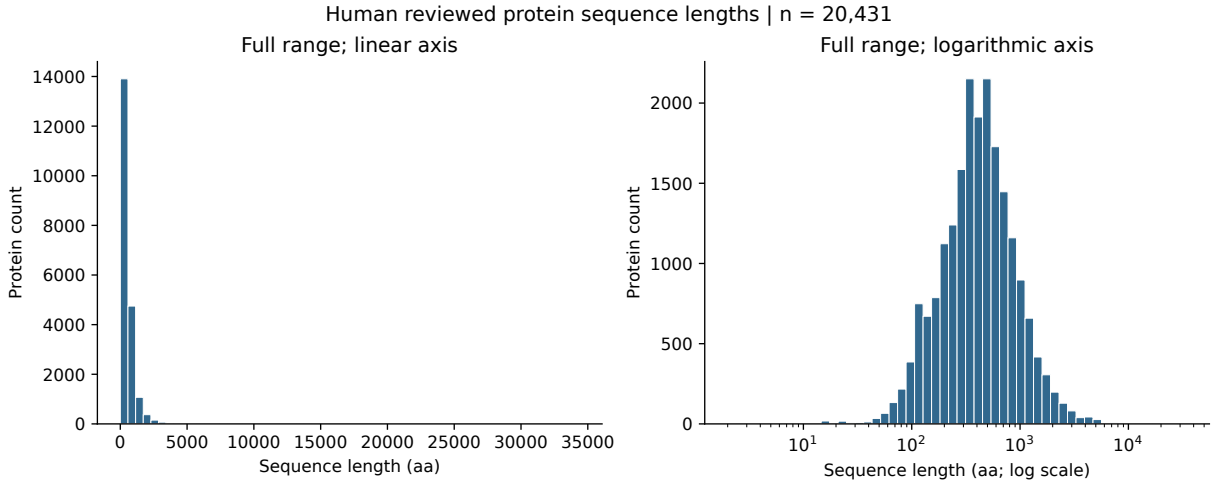


그림 1. 인간 Reviewed 단백질의 아미노산 서열 길이 분포

n = 20,431. 왼쪽은 전체 범위를 선형 축으로, 오른쪽은 전체 범위를 로그 축으로 나타낸 히스토그램이다. 서열 길이의 범위는 2-34,350 aa이며 모든 관측치를 포함하였다.

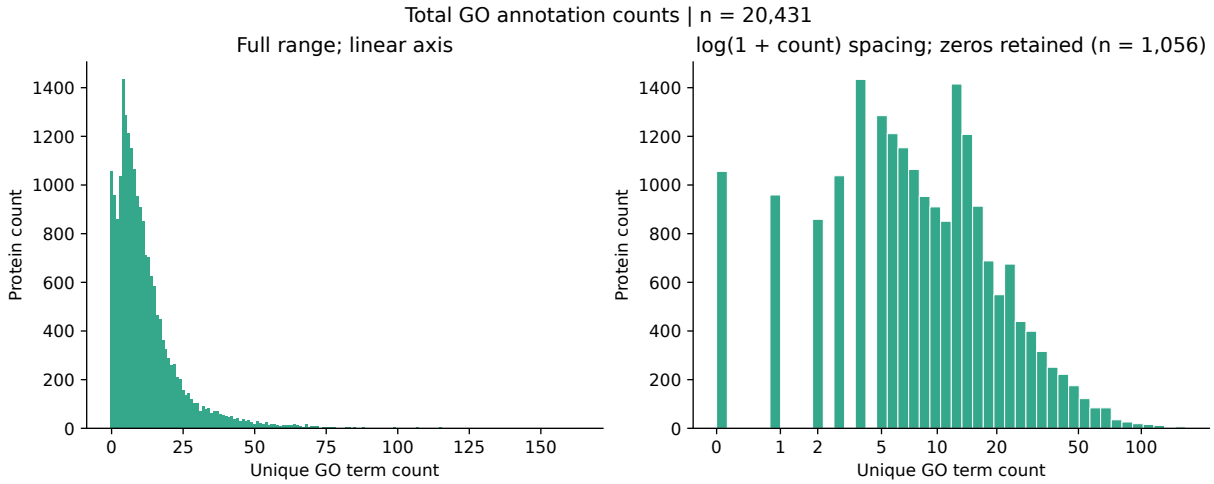


그림 2. 인간 Reviewed 단백질의 전체 고유 GO 주석 개수 분포

n = 20,431. 왼쪽은 선형 간격, 오른쪽은 log(1 + 개수) 간격을 사용한 히스토그램이다. GO 주석이 없는 1,056개 항목을 포함하여 전체 범위를 유지하였다.

3.2 아미노산 서열 길이와 전체 GO 주석 개수의 상관관계

아미노산 서열 길이와 전체 고유 GO 주석 개수 사이의 Spearman 순위상관계수는 0.2705로 나타났다(95% bootstrap CI [0.2570, 0.2840], 양측 $p \approx 2.21 \times 10^{-339}$; 표 2, 그림 3). 이는 인간 Reviewed 단백질에서 아미노산 서열 길이가 길수록 데이터베이스에 등록된 고유 GO 주석 개수가 많아지는 약한 양의 단조 연관성이 관찰되었음을 의미한다.

95% 신뢰구간이 0을 포함하지 않았으므로 주요 가설의 방향을 지지하는 통계적 근거가 확인되었다. 다만 동일한 서열 길이 구간에서도 GO 주석 개수의 변동이 크게 나타나, 서열 길이만으로 GO 주석 개수를 충분히 설명하기는 어려웠다.

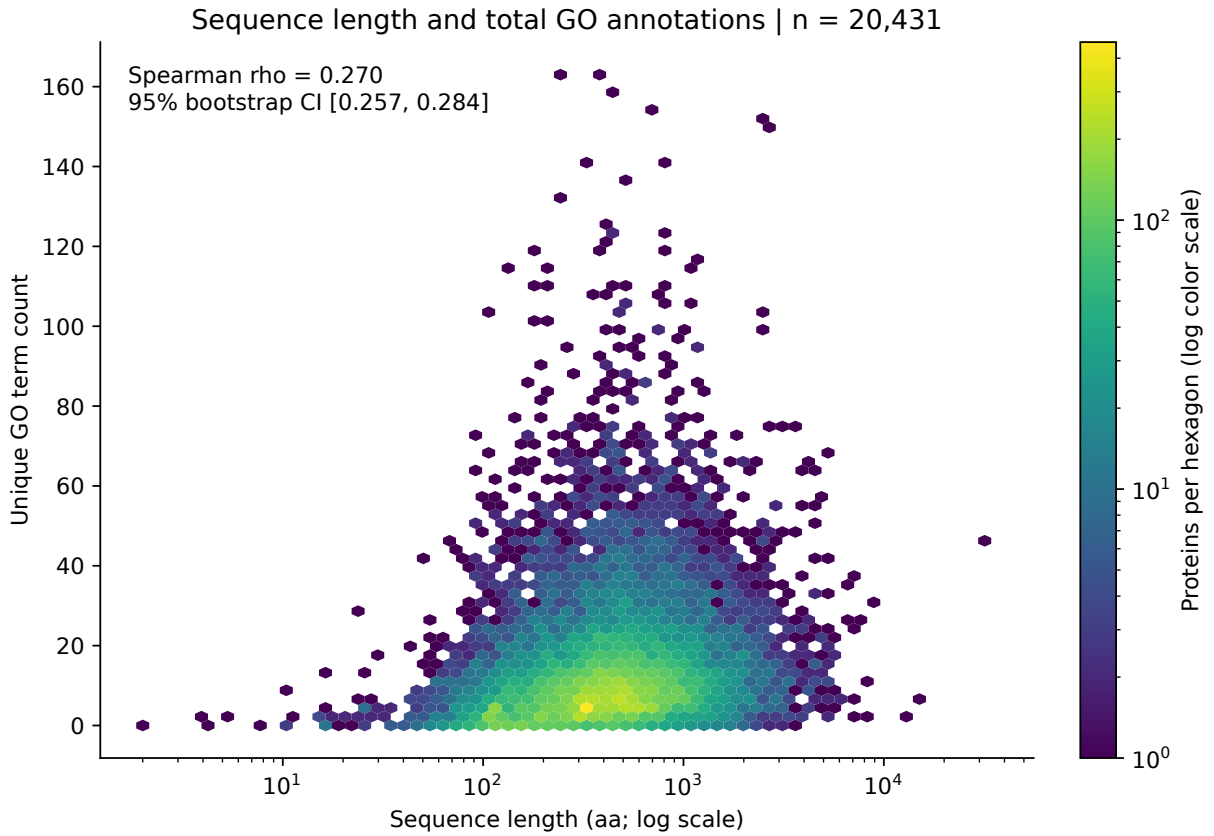


그림 3. 아미노산 서열 길이와 전체 고유 GO 주석 개수의 관계

n = 20,431. 가로축은 로그 축의 서열 길이, 세로축은 고유 GO ID 개수이다. 색은 각 육각형 구간에 속한 단백질 수를 로그 색상 척도로 나타낸다. GO 0개 항목도 포함하였다. ρ = 0.2705, 95% CI [0.2570, 0.2840]. 상관계수는 로그 변환으로 대체하지 않은 원자료의 순위로 계산하였다.

3.3 GO 범주별 상관관계

GO의 세 가지 범주를 구분하여 분석한 결과, 모든 범주에서 아미노산 서열 길이와 주석 개수 사이에 양의 상관관계가 관찰되었다(표 2, 그림 4).

표 2. 서열 길이와 GO 주석 개수의 Spearman 상관분석

분석 변수	ρ	95% CI	양측 p값	Holm 보정 p값
전체 GO	0.2705	[0.2570, 0.2840]	2.21×10^{-339}	-
BP	0.2280	[0.2151, 0.2416]	4.35×10^{-239}	4.35×10^{-239}
MF	0.2592	[0.2455, 0.2720]	8.56×10^{-311}	2.57×10^{-310}
CC	0.2464	[0.2330, 0.2596]	2.86×10^{-280}	5.72×10^{-280}

주: 모든 분석의 n = 20,431. CI는 2,000회 paired row bootstrap의 2.5% 및 97.5% 백분위수이다. 양측 p값은 큰 표본 t 근사로 계산하였다. Holm 보정은 보조 검정 BP·MF·CC 3개에만 적용하였다. 전체 GO의 p값은 부동소수점 언더플로를 보완한 계산값이며 0을 의미하지 않는다.

세 범주 모두 Holm 다중검정 보정 후에도 통계적으로 유의하였다. 상관계수의 점추정치는 MF에서 가장 높고 BP에서 가장 낮았으나, 범주 간 상관계수 차이에 대한 별도 통계적 검정은 수행하지 않았다.

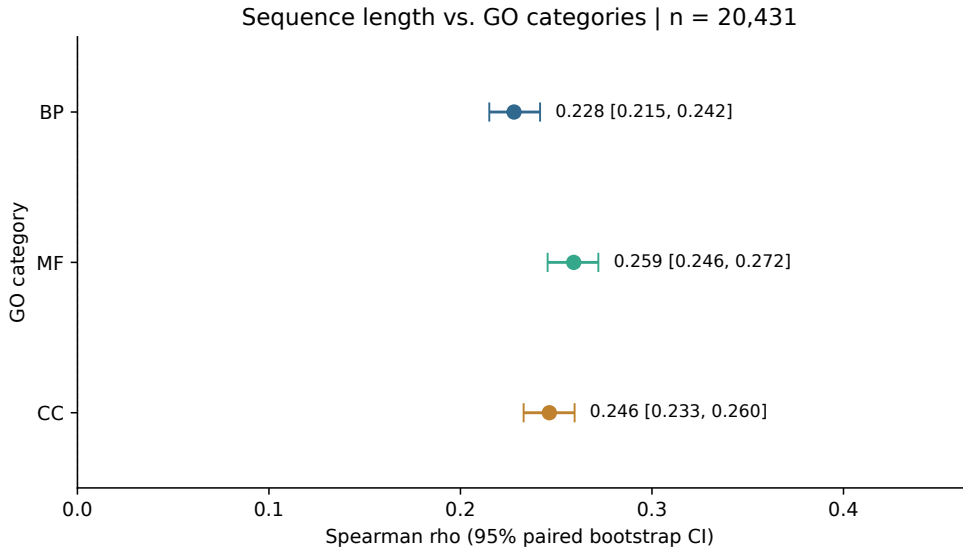


그림 4. GO 범주별 Spearman 상관계수 및 95% 신뢰구간

n = 20,431. 점은 BP·MF·CC별 상관계수, 가로 오차막대는 2,000회 paired row bootstrap 95% 백분위수 신뢰구간이다. 범주 간 상관계수 차이에 대한 통계적 검정은 수행하지 않았다.

3.4 민감도 분석

주요 분석 결과가 분석 대상 선정 기준에 따라 달라지는지 확인하기 위해 두 가지 민감도 분석을 수행하였다(표 3).

표 3. 분석 대상 선정 기준에 따른 민감도 분석

분석 조건	분석 대상 수	ρ	95% CI	기본 대비 Δρ
기본 분석	20,431	0.2705	[0.2570, 0.2840]	-
GO 0개 제외	19,375	0.2331	[0.2199, 0.2473]	-0.0373
유전자 기준	19,031	0.2013	[0.1879, 0.2155]	-0.0691

주: Δρ는 반올림하지 않은 상관계수를 기준으로 계산하였다. 유전자 기준 분석은 단일 Gene ID가 확인된 항목에서 Gene ID별 accession 오름차순 첫 항목을 선택한 결과이다. GO 0개 제외 및 유전자 기준 분석의 양측 p값은 각각 약 2.21×10^{-237}, 3.02×10^{-173}이었다. CI 산출 방식은 표 2와 같다.

첫 번째 분석에서는 GO 주석 개수가 0개인 단백질 1,056개를 제외하였다. 그 결과 Spearman 상관계수는 0.2331로 나타나 기본 분석보다 0.0373 감소했으나, 양의 상관관계는 유지되었다. 두 번째 분석에서는 단일 Gene ID가 확인되는 항목을 대상으로 유전자당 하나의 accession만 유지하였다. 이때 Gene ID 누락 1,277개, 복수 매핑 99개, 동일 Gene ID 중복 24개를 제외하여 최종 19,031개 항목을 분석하였다.

Spearman 상관계수는 0.2013으로 나타나 기본 분석보다 0.0691 감소했지만, 양의 연관성은 유지되었다. 다만 유전자 기준 분석에서는 Gene ID 정보의 가용성에 따른 대상 변화와 중복 축소가 함께 적용되었으므로, 상관계수 감소를 동일 유전자 중복 제거의 효과만으로 설명할 수는 없다.

4. 논의 (Discussion)

4.1 단백질 서열 길이와 GO 주석 개수의 연관성

본 연구에서는 인간 Reviewed 단백질 20,431개를 대상으로 아미노산 서열 길이와 고유 GO 주석 개수 사이의 관계를 분석하였다. 주요 분석 결과, Spearman 순위상관계수는 0.2705(95% CI [0.2570, 0.2840])로 나타나 약한 양의 단조 연관성이 관찰되었다. 이는 서열 길이가 긴 단백질일수록 데이터베이스에 등록된 GO 주석 개수가 많은 경향이 있음을 보여주며, 연구 질문에서 예상한 양의 방향과 일치한다.

그러나 관찰된 상관관계의 크기는 제한적이었다. 산점도에서도 비슷한 서열 길이를 가진 단백질 사이에 GO 주석 개수의 차이가 크게 나타났다. 따라서 아미노산 서열 길이는 GO 주석 개수와 관련된 특성 중 하나일 수 있으나, 단독으로 주석 개수의 차이를 충분히 설명한다고 보기는 어렵다. 특히 본 연구에서 측정한 고유 GO 주석 개수는 단백질의 실제 생물학적 기능 수를 직접 나타내는 지표가 아니다.

GO 주석은 단백질에 대해 데이터베이스에 기록된 기능 관련 정보이며, 주석의 생성과 축적에는 생물학적 특성뿐 아니라 연구 및 큐레이션 과정이 영향을 미칠 수 있다. 따라서 본 연구 결과를 서열 길이가 단백질의 기능적 다양성을 증가시킨다는 인과관계로 해석해서는 안 된다.

4.2 기존 연구와의 비교

Gillis와 Pavlidis [3]는 GO 주석의 중복성, 시간에 따른 변화 및 편향을 분석하여 인간 유전자에서 주석이 특정 유전자에 집중되는 현상을 보고하였다. 이러한 선행연구는 단백질이나 유전자별 GO 주석 개수가 균등하게 분포하지 않을 수 있으며, 주석 개수에 기반한 분석에서 편향을 고려해야 한다는 점을 보여준다. Phan 등 [5]은 인간 단백질체를 대상으로 기능 주석 정보의 분포를 종단적으로 분석하여 GO 기반 기능 정보의 불균등성이 지속되고 있음을 보고하였다.

또한 단백질에 대한 문헌상 연구 관심도와 데이터베이스에 축적된 기능 정보 사이에 차이가 존재함을 제시하였다. 본 연구에서도 GO 주석 개수는 오른쪽으로 긴 꼬리를 갖는 비대칭 분포를 보였으며, 일부 단백질은 다른 단백질보다 상당히 많은 주석을 보유하고 있었다. 이러한 관찰은 기존 연구에서 제기된 주석 정보의 불균등한 분포와 정성적으로 일치한다. 다만 본 연구에서는 주석 불균등성을 직접 측정하는 Gini 계수나 정보량 지표를 계산하지 않았으므로, 기존 연구와 주석 편향의 정도를 정량적으로 비교할 수는 없다.

또한 연구량과 GO 주석 개수 사이의 관계를 직접 검정하지 않았기 때문에, 관찰된 상관관계에서 연구 관심도가 어느 정도 영향을 미쳤는지는 확인할 수 없다. Gaudet과 Dessimoz [4]는 GO 주석의 불완전성, 근거 정보, 계층 구조 및 분석 과정의 편향을 고려해야 한다고 설명하였다. 이러한 관점에서 본 연구의 결과 역시 GO 주석의 생물학적 의미와 데이터베이스 기록량을 구분하여 해석할 필요가 있다.

4.3 GO 범주별 분석 결과

GO의 세 가지 범주를 구분한 분석에서도 서열 길이와 주석 개수 사이에 모두 양의 연관성이 관찰되었다. Spearman 상관계수는 BP에서 0.2280, MF에서 0.2592, CC에서 0.2464로 나타났다. 세 범주 모두 주요 분석과 동일한 방향의 연관성을 보였다는 점은 서열 길이와 GO 주석 개수 사이의 관계가 특정 범주에서만 관찰된 현상은 아니라는 점을 보여준다. 다만 범주별 상관계수의 차이는 크지 않았으며, 본 연구에서는 범주 간 상관계수 차이에 대한 별도의 통계적 검정을 수행하지 않았다.

따라서 MF의 상관계수가 BP나 CC보다 높게 관찰되었다는 사실만으로 분자 기능 주석이 서열 길이와 생물학적으로 더 밀접하게 연결되어 있다고 결론 내릴 수는 없다.

4.4 민감도 분석과 연구 결과의 강건성

주요 분석 결과가 데이터 선정 기준에 따라 달라지는지 확인하기 위해 두 가지 민감도 분석을 수행하였다. 첫 번째 분석에서는 GO 주석이 0개인 단백질 1,056개를 제외하였다. 그 결과 상관계수는 0.2705에서 0.2331로 감소했으나, 양의 연관성은 유지되었다. 이는 주석이 없는 단백질을 포함하는지 여부가 관찰된 연관성의 크기에 영향을 줄 수 있음을 보여준다. 두 번째 분석에서는 단일 Gene ID가 확인된 항목만을 대상으로 유전자당 하나의 accession을 유지하였다.

이때 상관계수는 0.2013으로 감소했지만, 양의 방향은 유지되었다. 그러나 이 분석에서는 Gene ID가 누락된 1,277개 항목, 복수 Gene ID에 매핑된 99개 항목, 동일 Gene ID를 공유하여 중복 축소된 24개 항목이 제외되었다. 따라서 상관계수 감소를 동일 유전자 중복 제거의 효과만으로 설명할 수는 없다. Gene ID의 가용성에 따른 분석 대상 변화가 함께 작용했을 가능성이 있다.

종합하면 두 민감도 분석에서도 주요 가설과 동일한 방향의 연관성이 유지되었다. 반면 상관계수의 크기는 분석 대상 선정 기준에 따라 달라졌으므로, 본 연구의 결과는 방향 측면에서는 비교적 일관되지만 효과 크기 측면에서는 일정한 민감성을 보인다고 해석할 수 있다.

4.5 연구의 한계

본 연구에는 다음과 같은 한계가 있다. 첫째, 단일 UniProtKB 릴리스(2026_03)의 인간 Reviewed 단백질만을 대상으로 분석하였다. 따라서 결과를 다른 생물종이나 다른 시점의 데이터베이스에 그대로 일반화할 수는 없다. 둘째, GO 주석의 근거 수준을 구분하지 않았다. Reviewed 단백질 항목에도 실험적 근거와 계산적 추론에 기반한 GO 주석이 포함될 수 있다. 본 연구에서는 증거 코드와 관계없이 고유 GO ID 개수를 집계했으므로, 주석 근거의 차이가 분석 결과에 미치는 영향을 평가하지 못했다.

셋째, 단백질별 연구량, 단백질군, 구조적 도메인 수, 주석의 정보량 등 잠재적인 교란 요인을 통제하지 않았다. 따라서 관찰된 연관성이 서열 길이 자체와 관련된 정도를 분리해 추정할 수 없다. 넷째, 분석 단위는 UniProtKB primary accession이었다. 동일 유전자에 관련된 단백질 항목이나 단백질군 사이에 통계적 의존성이 존재할 가능성이 있으며, 본 연구의 기본 상관분석과 부트스트랩 신뢰구간은 이러한 의존성을 별도로 모형화하지 않았다.

다섯째, 연구 대상은 특정 릴리스에서 조건에 해당하는 전체 데이터베이스 항목이다. 따라서 통계적 유의확률과 부트스트랩 신뢰구간은 이 고정된 데이터베이스 자체의 표본추출 불확실성이 아니라 관측 항목을 교환 가능한 표본으로 간주하는 모형 기반 추론으로 해석해야 한다.

4.6 후속 연구 방향

향후 연구에서는 GO Evidence Code를 이용해 실험 기반 주석과 계산적 추론 주석을 구분하여 분석할 수 있다. 또한 단백질별 문헌 수나 구조적 도메인 수를 추가 변수로 활용하면, 서열 길이와 GO 주석 개수 사이의 관계를 보다 세부적으로 검토할 수 있을 것이다. 다른 UniProtKB 릴리스나 생물종을 대상으로 동일한 분석을 반복하면 관찰된 연관성이 시간과 생물종에 따라 유지되는지도 확인할 수 있다.

이러한 후속 분석은 본 연구에서 관찰된 약한 양의 상관관계가 어떤 요인들과 관련되어 있는지 이해하는 데 도움이 될 것이다.

5. 결론 (Conclusion)

본 연구에서는 UniProtKB Reviewed에 등록된 인간 단백질 20,431개를 대상으로 아미노산 서열 길이와 고유 Gene Ontology(GO) 주석 개수 사이의 관계를 분석하였다. Spearman 순위상관분석 결과, 서열 길이와 전체 GO 주석 개수 사이에는 약한 양의 상관관계가 관찰되었다($\rho = 0.2705$, 95% CI [0.2570, 0.2840]). BP, MF, CC 범주별 분석에서도 동일한 방향의 연관성이 확인되었으며, GO 주석이 없는 단백질을 제외하거나 유전자 기준으로 분석 대상을 제한한 민감도 분석에서도 양의 연관성은 유지되었다.

따라서 관찰된 데이터는 연구 질문에서 예상한 양의 연관성을 지지하였다. 그러나 상관관계의 크기는 제한적이었으며, 분석 대상 선정 기준에 따라 상관계수가 달라졌다. 본 연구는 인간 Reviewed 단백질의 서열 길이와 데이터베이스에 기록된 GO 주석량 사이의 관계를 재현 가능한 방식으로 정량화했다는 의의가 있다. 다만 GO 주석 개수는 실제 생물학적 기능 수와 동일하지 않으며, 연구 관심도와 주석 근거 등 잠재적인 편향 요인을 통제하지 않았으므로 인과적 해석은 제한된다.

향후에는 주석 근거 수준과 단백질의 추가적인 생물학적 특성을 고려하여 이러한 관계를 보다 정밀하게 분석할 필요가 있다.

참고문헌

[1] The UniProt Consortium. (2025). UniProt: the Universal Protein Knowledgebase in 2025. *Nucleic Acids Research, 53*(D1), D609-D617.
https://doi.org/10.1093/nar/gkae1010

[2] The Gene Ontology Consortium. (2023). The Gene Ontology knowledgebase in 2023. *Genetics, 224*(1), iyad031.
https://doi.org/10.1093/genetics/iyad031

[3] Gillis, J., & Pavlidis, P. (2013). Assessing identity, redundancy and confounds in Gene Ontology annotations over time. *Bioinformatics, 29*(4), 476-482.
https://doi.org/10.1093/bioinformatics/bts727

[4] Gaudet, P., & Dessimoz, C. (2017). Gene Ontology: Pitfalls, Biases, and Remedies. In C. Dessimoz & N. Škunca (Eds.), *The Gene Ontology Handbook* (Methods in Molecular Biology, Vol. 1446, pp. 189-205). Humana Press.
https://doi.org/10.1007/978-1-4939-3743-1_14

[5] Phan, A., Joshi, P., Kadelka, C., & Friedberg, I. (2025). A longitudinal analysis of function annotations of the human proteome reveals consistently high biases. *Database, 2025*, baaf036.
https://doi.org/10.1093/database/baaf036

[6] Ahmad, S., da Costa Gonzales, L. J., Bowler-Barnett, E. H., et al. (2025). The UniProt website API: facilitating programmatic access to protein knowledge. *Nucleic Acids Research, 53*(W1), W547-W553.
https://doi.org/10.1093/nar/gkaf394